Περιεχόμενα

Οι βιβλιοθήκες που χρησιμοποιήθηκαν **2**
Βασική δομή της εφαρμογής **3**
Γενικά χαρακτηριστικά διεπαφής χρήστη (UI) **4**
Περιγραφή ενοτήτων της εφαρμογής **4**
1. Sources 5
1.1 Πρωτοσέλιδα 5
1.2 Ριζοσπάστης – 902 5
1.3 News 6
1.4 Economy 6
1.5 Global Economy 6
1.6 International 6
1.7 Parapolitics 6
1.8 Parliament – Government 6
1.9 Podcasts – Radios 7
1.10 Notes 7
2. Agenda 7
2.1 Agenda 7
2.2 Journal 8
2.3 Notebook 8
3. Databases 8
4. Newsroom Tools 9
4.1 Editor 9
4.2 Newsroom Tools 9
4.3 Transcribe 10
4.4 OCR 10
4.5 From one to another 10
5. Economy Tools 10
5.1 Working Area 11
5.2 Open PDFs 11
5.3 Data 11
5.4 Charts 12
5.5 Tools 12
6. NLP 12
6.1 NLP 12
6.2 Relation Extraction
Η υποενότητα Relation Extraction υποστηρίζει τη δημιουργία διαγραμμάτων που απεικονίζουν σχέσεις μεταξύ οντοτήτων, όπως εταιρείες, πρόσωπα και όροι. Το περιβάλλον παρέχει: 13
7. GPTs - RAGs 13
Σχεδιαστικές αρχές και ροές εργασίας - κριτική αποτίμηση της εφαρμογής στο πλαίσιο των ΨΑΕ (πλεονεκτήματα, περιορισμοί, ερευνητική αξία). να συνδέσουμε ρητά τις ενότητες με θεωρητικά σχήματα των ΨΑΕ (αρχειακές πρακτικές, ροές πληροφορίας, ψηφιακή επιμέλεια), ή να περάσουμε σε κεφάλαιο "Σενάρια χρήσης (use cases)" της εφαρμογής. **14**

Οι βιβλιοθήκες που χρησιμοποιήθηκαν

Για την υλοποίηση της εφαρμογής αξιοποιήθηκε σύνολο βιβλιοθηκών της γλώσσας προγραμματισμού Python, οι οποίες υποστηρίζουν τη δημιουργία διαδραστικών διεπαφών, την επεξεργασία και ανάλυση δεδομένων, καθώς και τη διαχείριση εγγράφων και αρχείων.

Συγκεκριμένα αξιοποιήθηκαν οι εξής βιβλιοθήκες (με μια σύντομη περιγραφή).

- **streamlit**
  Δημιουργία διαδραστικών web εφαρμογών σε Python για παρουσίαση και επεξεργασία δεδομένων.
- **streamlit_option_menu**
  Δημιουργία μενού επιλογών (sidebars, navigation menus) στο Streamlit.
- **streamlit_navigation_bar**
  Υλοποίηση γραμμής πλοήγησης (navigation bar) για πολυσέλιδες εφαρμογές Streamlit.
- **streamlit.components.v1**
  Ενσωμάτωση προσαρμοσμένων HTML, CSS και JavaScript στοιχείων.
- **streamlit_pdf_viewer**
  Προβολή PDF αρχείων απευθείας μέσα στην εφαρμογή Streamlit.
- **pandas**
  Ανάλυση, επεξεργασία και διαχείριση δομημένων δεδομένων (πίνακες, CSV, Excel).
- **plotly.express**
  Δημιουργία διαδραστικών γραφημάτων και οπτικοποιήσεων δεδομένων.
- **requests**
  Αποστολή HTTP αιτημάτων για ανάκτηση δεδομένων από APIs ή ιστοσελίδες.
- **BeautifulSoup (bs4)**
  Εξαγωγή και ανάλυση δεδομένων από HTML/XML έγγραφα (web scraping).
- **webbrowser**
  Άνοιγμα ιστοσελίδων στον προεπιλεγμένο φυλλομετρητή του χρήστη.
- **natural_pdf**
  Ανάγνωση και επεξεργασία PDF με έμφαση στη φυσική δομή του κειμένου.

- **fitz (PyMuPDF)**
  Προηγμένη επεξεργασία PDF αρχείων (ανάγνωση, εξαγωγή κειμένου και εικόνων).
- **pdfplumber**
  Εξαγωγή κειμένου και πινάκων από PDF αρχεία με ακρίβεια διάταξης.
- **PyPDF2**
  Βασική διαχείριση PDF αρχείων (ανάγνωση, συγχώνευση, διαχωρισμός).
- **python-docx / docx**
  Δημιουργία και επεξεργασία εγγράφων Microsoft Word (.docx).
- **Pillow (PIL.Image)**
  Φόρτωση και επεξεργασία εικόνων.
- **sqlite3**
  Διαχείριση τοπικής βάσης δεδομένων SQLite.
- **os**
  Αλληλεπίδραση με το λειτουργικό σύστημα (αρχεία, φάκελοι, μεταβλητές περιβάλλοντος).
- **pathlib**
  Αντικειμενοστραφής διαχείριση διαδρομών αρχείων.
- **tempfile**
  Δημιουργία προσωρινών αρχείων και καταλόγων.
- **zipfile**
  Συμπίεση και αποσυμπίεση αρχείων ZIP.
- **io (BytesIO, StringIO)**
  Διαχείριση δεδομένων στη μνήμη ως streams (π.χ. αρχεία χωρίς αποθήκευση σε δίσκο).
- **base64**
  Κωδικοποίηση και αποκωδικοποίηση δεδομένων (π.χ. για μεταφορά αρχείων).
- **json**
  Ανάγνωση και εγγραφή δεδομένων σε μορφή JSON.
- **yaml**
  Διαχείριση αρχείων ρυθμίσεων σε μορφή YAML.
- **datetime (datetime, date, timedelta)**
  Διαχείριση ημερομηνιών, χρόνου και χρονικών υπολογισμών.

Βασική δομή της εφαρμογής

Η εφαρμογή έχει ως βασικό στόχο τη συγκέντρωση, σε ένα ενιαίο ψηφιακό περιβάλλον, μίας σειράς εργαλείων τα οποία χρησιμοποιεί ένας δημοσιογράφος σε καθημερινή βάση κατά τη διαδικασία παραγωγής ειδησεογραφικού περιεχομένου. Η προσέγγιση αυτή αποσκοπεί στη μείωση του κατακερματισμού των εργασιών και στη βελτίωση της οργανωμένης διαχείρισης πληροφορίας.

Το παραπάνω σκεπτικό επιχειρήθηκε να αποτυπωθεί και στη δομή της εφαρμογής, η οποία, σε αδρές γραμμές, καλύπτει τις ακόλουθες βασικές λειτουργικές περιοχές:

- την ανάγνωση ειδήσεων και την αξιοποίηση ποικίλων πηγών πληροφόρησης, καθώς και τη δυνατότητα καταγραφής σημειώσεων,
- τη διαμόρφωση και οργάνωση της καθημερινής ειδησεογραφικής ατζέντας,
- την αναδρομή στο αρχείο ειδήσεων, τόσο σε συλλογικό όσο και σε προσωπικό επίπεδο,
- τη συγγραφή ειδήσεων, η οποία προϋποθέτει την υποστήριξη σύνθετων λειτουργιών και τη χρήση επιμέρους εργαλείων.

Με οδηγό τις παραπάνω λειτουργικές κατηγορίες —χωρίς ωστόσο να υφίσταται απόλυτη αντιστοίχιση τύπου «ένα προς ένα»— διαμορφώθηκε η συνολική αρχιτεκτονική και η πλοήγηση της εφαρμογής.

Γενικά χαρακτηριστικά διεπαφής χρήστη (UI)

Η διεπαφή χρήστη της εφαρμογής σχεδιάστηκε με στόχο τη σαφή οργάνωση των λειτουργιών και τη διευκόλυνση της αλληλεπίδρασης του χρήστη. Τα βασικά δομικά χαρακτηριστικά του γραφικού περιβάλλοντος έχουν ως εξής:

- Στην αριστερή στήλη της οθόνης βρίσκεται το κύριο μενού επιλογών, μέσω του οποίου ο χρήστης αποκτά πρόσβαση στις βασικές ενότητες της εφαρμογής.
- Στο επάνω μέρος κάθε βασικής ενότητας εμφανίζονται καρτέλες (tabs), οι οποίες αντιστοιχούν στις επιμέρους λειτουργίες της εκάστοτε ενότητας.
- Στο δεξί τμήμα της διεπαφής έχει διαμορφωθεί ένα «control panel», στο οποίο συγκεντρώνονται τα βασικά στοιχεία ελέγχου και οι κύριες εντολές που αφορούν την ενεργή ενότητα.

- Στο κεντρικό τμήμα της οθόνης προβάλλονται τα αποτελέσματα των ενεργειών του χρήστη, καθώς και το κύριο περιεχόμενο εργασίας.

Περιγραφή ενοτήτων της εφαρμογής

Αναλυτικότερα, η εφαρμογή οργανώνεται σε επιμέρους ενότητες, καθεμία από τις οποίες αντιστοιχεί σε διακριτές πρακτικές και ανάγκες της δημοσιογραφικής εργασίας.

1. **Sources**

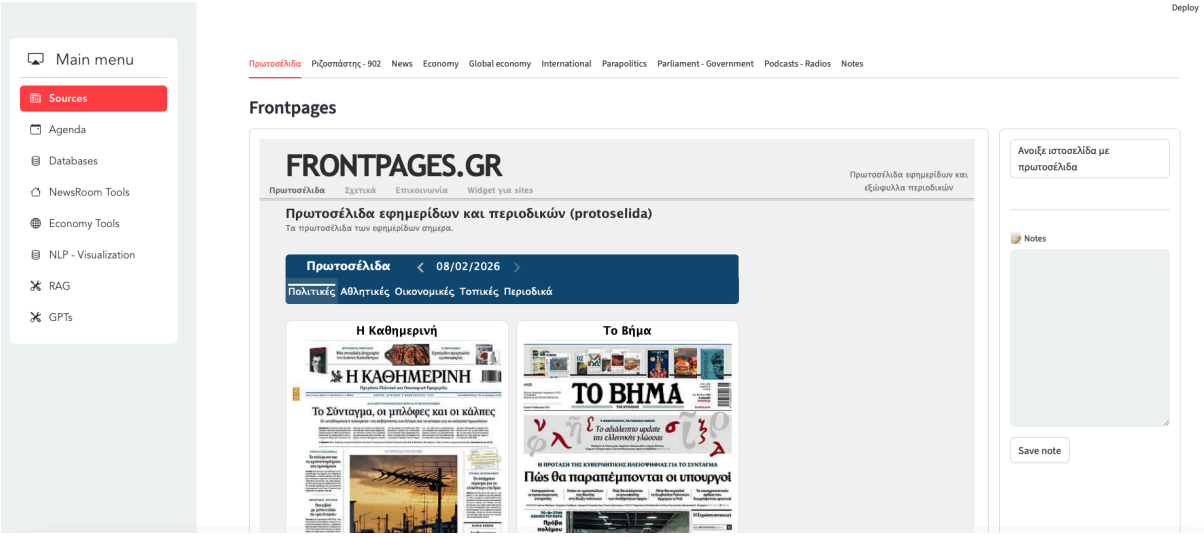

Εικόνα 1 - Στιγμιότυπο από την αρχική σελίδα της ενότητας Sources

Η ενότητα **Sources** συγκεντρώνει το σύνολο των πηγών πληροφόρησης που αξιοποιούνται κατά τη διαδικασία ενημέρωσης και προκαταρκτικής έρευνας. Αποτελεί το βασικό σημείο πρόσβασης σε ειδησεογραφικό περιεχόμενο και λειτουργεί ως κόμβος συγκέντρωσης πρωτογενούς υλικού.

1.1 Πρωτοσέλιδα

Στην υποενότητα αυτή προβάλλονται τα πρωτοσέλιδα των ημερήσιων εφημερίδων μέσω ενσωματωμένης ζωντανής σελίδας (iframe) της ιστοσελίδας *frontpages.gr*. Παράλληλα, παρέχεται η δυνατότητα:

- ανοίγματος της σχετικής ιστοσελίδας μέσω εξωτερικού συνδέσμου,
- καταγραφής σημειώσεων στο πεδίο *Notes*.

Το κείμενο των σημειώσεων εισάγεται μέσω στοιχείου `st.text_area` και, κατόπιν σχετικής εντολής, αποθηκεύεται σε αρχείο μορφής `.txt`. Το αποθηκευμένο περιεχόμενο είναι διαθέσιμο προς ανάγνωση στην τελευταία καρτέλα της ενότητας.

1.2 Ριζοσπάστης – 902

Η συγκεκριμένη υποενότητα επικεντρώνεται στην εφημερίδα *Ριζοσπάστης* και στην ειδησεογραφική ιστοσελίδα *902.gr*. Μέσω αναδυόμενου μενού (drop-down menu) στο δεξί τμήμα της διεπαφής, ο χρήστης έχει τη δυνατότητα να επιλέξει μεταξύ των ακόλουθων λειτουργιών:

- προβολή της ιστοσελίδας της εφημερίδας μέσω iframe,
- προβολή των βασικών θεμάτων, με αξιοποίηση τεχνολογιών ανάγνωσης ροών ειδήσεων (RSS),
- προβολή του κεντρικού άρθρου της ημέρας,
- αποθήκευση επιλεγμένων άρθρων σε τοπική βάση δεδομένων (SQLite),
- προβολή του περιεχομένου της σχετικής βάσης δεδομένων,
- προβολή της ροής RSS της ιστοσελίδας *902.gr*,
- άνοιγμα εξωτερικών συνδέσμων προς τις ιστοσελίδες *Ριζοσπάστης* και *902*,
- καταγραφή σημειώσεων.

1.3 News

Στην ενότητα **News**, στο κεντρικό τμήμα της οθόνης προβάλλεται —όπου αυτό είναι τεχνικά εφικτό— η ειδησεογραφική ιστοσελίδα που επιλέγει ο χρήστης, μέσω ενσωματωμένης προβολής (iframe). Στο δεξί τμήμα της διεπαφής, ο χρήστης μπορεί αρχικά να επιλέξει ομάδα μέσων και, στη συνέχεια, το συγκεκριμένο μέσο ενημέρωσης.

1.4 Economy

Η ενότητα **Economy** λειτουργεί αντίστοιχα με την ενότητα *News*, με τη διαφορά ότι επικεντρώνεται αποκλειστικά στην προβολή και παρακολούθηση οικονομικών ειδήσεων από επιλεγμένα μέσα ενημέρωσης.

1.5 Global Economy

Η ενότητα **Global Economy** αφορά ειδήσεις που σχετίζονται με τη διεθνή οικονομία και ακολουθεί την ίδια λειτουργική λογική με τις προηγούμενες ενότητες, προσαρμοσμένη στο αντίστοιχο θεματικό πεδίο.

1.6 International

Η ενότητα **International** περιλαμβάνει διεθνείς ειδήσεις γενικού ενδιαφέροντος και υλοποιείται με παρόμοιο τρόπο, επιτρέποντας στον χρήστη να παρακολουθεί διεθνή ειδησεογραφικά μέσα.

1.7 Parapolitics

Στην ενότητα **Parapolitics** προβάλλεται περιεχόμενο που εντάσσεται στην κατηγορία των λεγόμενων «παραπολιτικών» ειδήσεων. Εκτός από τη δυνατότητα απλής προβολής των σχετικών ιστοσελίδων, παρέχεται λειτουργία αυτόματης συλλογής (web scraping) θεμάτων της ημέρας από επιλεγμένες πηγές, μέσω της επιλογής *open rss main parapolitics*.

1.8 Parliament – Government

Η ενότητα **Parliament – Government** αξιοποιεί τεχνικές συλλογής δεδομένων από τον ιστό (web scraping) και παρέχει στον χρήστη πρόσβαση σε πληροφορίες σχετικές με το κοινοβουλευτικό και κυβερνητικό έργο. Συγκεκριμένα, προσφέρεται η δυνατότητα προβολής:

- του προγράμματος των κοινοβουλευτικών επιτροπών για την τρέχουσα εβδομάδα,
- των πρακτικών των συνεδριάσεων της Βουλής,
- της ιστοσελίδας *Vouliwatch*, η οποία επικεντρώνεται στο κοινοβουλευτικό ρεπορτάζ,
- εξωτερικών συνδέσμων προς τις επίσημες ιστοσελίδες της Γενικής Γραμματείας Ενημέρωσης και του Πρωθυπουργού.

1.9 Podcasts – Radios

Στην ενότητα **Podcasts – Radios** παρέχεται η δυνατότητα παρακολούθησης επιλεγμένων podcast μέσω ενσωματωμένου video player, αξιοποιώντας το στοιχείο st.video.

1.10 Notes

Η ενότητα **Notes** λειτουργεί ως κεντρικός χώρος συγκέντρωσης και διαχείρισης των σημειώσεων που έχουν παραχθεί κατά την πλοήγηση του χρήστη στις προηγούμενες ενότητες και πηγές. Μέσω των διαθέσιμων εργαλείων στο δεξί τμήμα της διεπαφής, ο χρήστης μπορεί να πραγματοποιήσει ενέργειες όπως:

- διαλογή και κατηγοριοποίηση των σημειώσεων,
- καταγραφή τους σε πίνακα δεδομένων (dataframe) με προκαθορισμένα θεματικά πεδία (π.χ. οικονομία, πολιτική), για την οργάνωση και παραπέρα αξιοποίηση

- προβολή και καθαρισμό (editing/cleaning) του περιεχομένου,
- προβολή συγκεντρωτικού πίνακα όλων των πηγών που έχουν χρησιμοποιηθεί.

2. Agenda

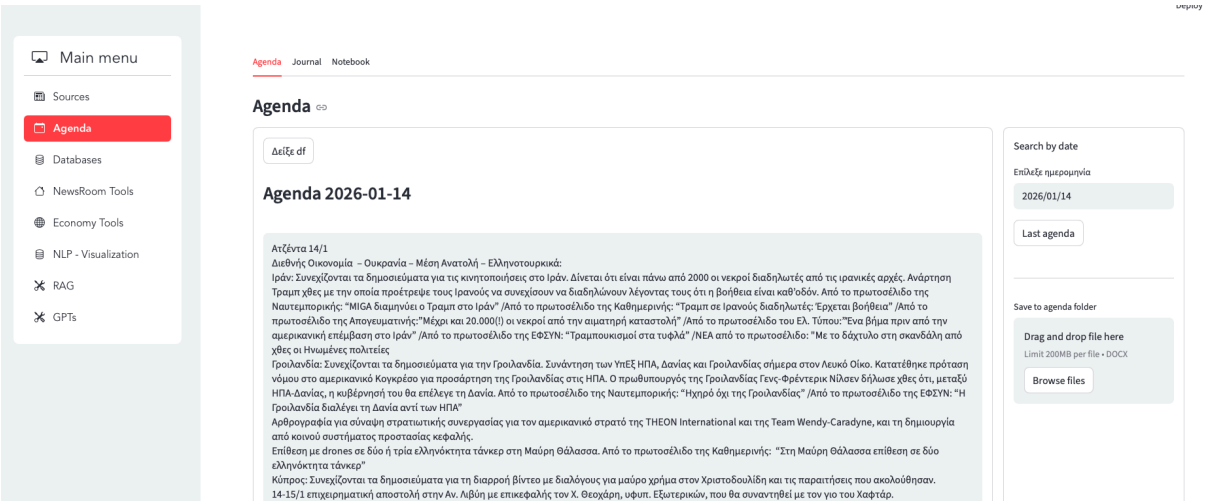

Εικόνα 2 - Η αρχική σελίδα της Ενότητας "Agenda"

Η ενότητα **Agenda** αφορά την οργάνωση και διαχείριση της καθημερινής εργασιακής ροής του δημοσιογράφου και συγκεντρώνει εργαλεία που σχετίζονται με τον προγραμματισμό, την καταγραφή υποχρεώσεων και τη διατήρηση προσωπικών σημειώσεων.

2.1 Agenda

Στην υποενότητα **Agenda** προβάλλονται αρχεία μορφής `.txt` που αντιστοιχούν στην ατζέντα της εκάστοτε ημέρας. Το σύστημα αντλεί αυτόματα τα αρχεία αυτά από προκαθορισμένο φάκελο, ενώ μέσω του σχετικού μενού δίνεται η δυνατότητα επιλογής συγκεκριμένης ημερομηνίας για την προβολή παλαιότερης ή μελλοντικής ατζέντας. Επιπλέον, παρέχεται λειτουργία προβολής του περιεχομένου των αρχείων σε μορφή πίνακα, ο οποίος μπορεί να εξαχθεί, ενδεικτικά, σε αρχείο Excel. Στην ίδια υποενότητα, ο χρήστης έχει τη δυνατότητα να ανεβάσει αρχείο μορφής `.doc` ή `.docx`, το περιεχόμενο του οποίου αποθηκεύεται αυτόματα ως αρχείο `.txt` στον αντίστοιχο φάκελο ατζέντας.

2.2 Journal

Η υποενότητα **Journal** υλοποιεί ένα αυτοσχέδιο ψηφιακό ημερολόγιο εργασιών. Παρέχεται η δυνατότητα προβολής των καταγεγραμμένων εργασιών (tasks) που αφορούν τη

συγκεκριμένη ημέρα, την τρέχουσα εβδομάδα ή μια επιλεγμένη ημερομηνία. Παράλληλα, ο χρήστης μπορεί να προσθέσει νέα εργασία, συνοδευόμενη από σύντομη περιγραφή, ενισχύοντας τη λειτουργία προγραμματισμού και παρακολούθησης της καθημερινής δραστηριότητας.

2.3 Notebook

Η υποενότητα **Notebook** λειτουργεί ως απλό ψηφιακό σημειωματάριο. Προβάλλει σημειώσεις που είναι αποθηκευμένες σε προκαθορισμένο αρχείο και δίνει τη δυνατότητα στον χρήστη να επεξεργαστεί το περιεχόμενο ή να αποθηκεύσει νέες σημειώσεις σε ξεχωριστό αρχείο, ενισχύοντας την ευελιξία στη διαχείριση προσωπικών καταγραφών.

3. Databases

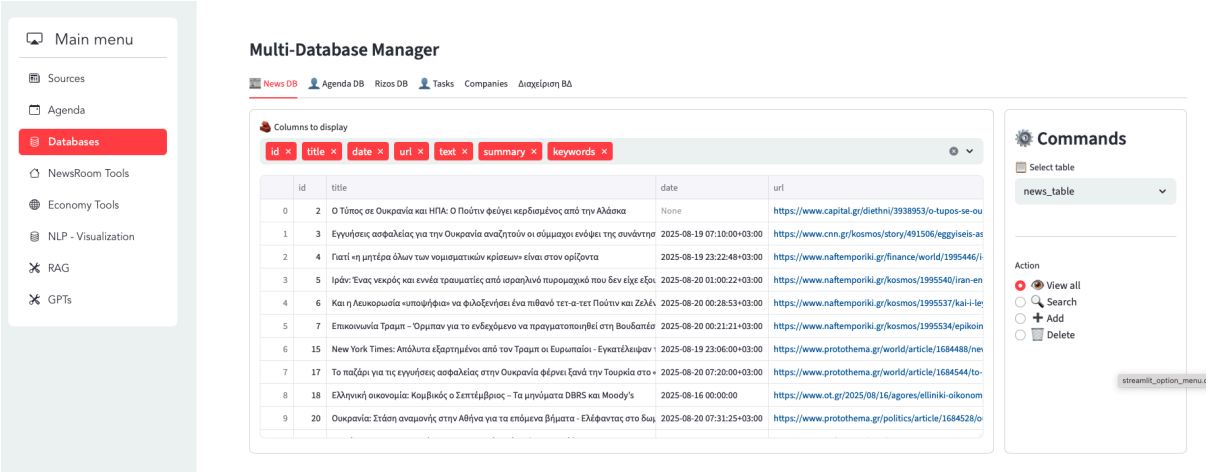

Εικόνα 3 - Στιγμιότυπο των databases

Η ενότητα **Databases** φιλοξενεί τις βάσεις δεδομένων που αξιοποιούνται στο πλαίσιο του έργου, οι οποίες υλοποιούνται με τη χρήση SQLite. Όλες οι υποενότητες ακολουθούν ενιαία λογική διάταξης και λειτουργικότητας· ως εκ τούτου, αρκεί η αναλυτική περιγραφή μίας εξ αυτών.

Μέσω της δεξιάς στήλης της διεπαφής, ο χρήστης μπορεί να επιλέξει τον πίνακα της βάσης δεδομένων που επιθυμεί να εξετάσει. Στη συνέχεια, από το κεντρικό τμήμα της οθόνης, έχει τη δυνατότητα να επιλέξει ποιες στήλες του πίνακα θα εμφανίζονται. Παρέχονται, επιπλέον, βασικές λειτουργίες διαχείρισης δεδομένων, όπως η προβολή όλων των εγγραφών, η αναζήτηση σε συγκεκριμένα πεδία, καθώς και η προσθήκη ή διαγραφή εγγραφών.

Η ίδια λειτουργική λογική εφαρμόζεται σε όλες τις επιμέρους καρτέλες της ενότητας. Αξίζει να σημειωθεί ότι η βάση δεδομένων **News DB** έχει πειραματικό χαρακτήρα, καθώς

δημιουργήθηκε μέσω διαδικασιών αυτόματης συλλογής περιεχομένου (web scraping) από επιλεγμένες ιστοσελίδες. Η συλλογή βασίζεται στην αναζήτηση συγκεκριμένων λέξεων-κλειδιών στους τίτλους των ειδήσεων, ενώ το σχετικό περιεχόμενο κατηγοριοποιείται αυτόματα.

Στην τελευταία καρτέλα της ενότητας, με τίτλο **Διαχείριση ΒΔ**, ο χρήστης έχει τη δυνατότητα να ενεργοποιήσει τις διαδικασίες συλλογής δεδομένων, να προβάλει επιλεγμένες ενότητες των βάσεων δεδομένων, καθώς και να δημιουργήσει νέα βάση δεδομένων.

4. Newsroom Tools

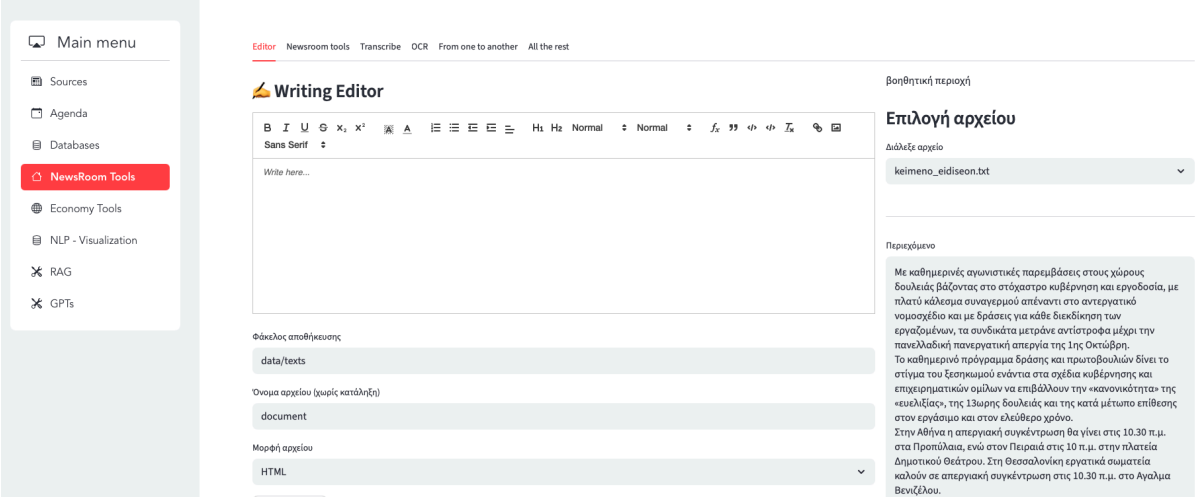

Εικόνα 4 - Η αρχική σελίδα των “Newsroom tools”

Η ενότητα **Newsroom Tools** αποτελεί τον βασικό χώρο επεξεργασίας και παραγωγής ειδησεογραφικού περιεχομένου. Συγκεντρώνει εργαλεία που υποστηρίζουν το σύνολο της διαδικασίας σύνταξης, επιμέλειας και μετασχηματισμού κειμένων, αξιοποιώντας τόσο παραδοσιακές λειτουργίες επεξεργασίας όσο και σύγχρονες τεχνικές υποβοήθησης μέσω μοντέλων τεχνητής νοημοσύνης.

4.1 Editor

Στην υποενότητα **Editor**, στο κεντρικό τμήμα της διεπαφής, παρέχεται ένας εμπλουτισμένος κειμενογράφος, ο οποίος υλοποιείται μέσω του προσαρμοσμένου Streamlit component `st_quill`, βασισμένου στον ευρέως διαδεδομένο rich text editor *Quill.js*. Ο κειμενογράφος προσφέρει δυνατότητες μορφοποίησης κειμένου, εισαγωγής εικόνων, δημιουργίας υπερσυνδέσμων και γενικότερης επιμέλειας περιεχομένου.

Παράλληλα, παρέχεται η δυνατότητα αποθήκευσης του παραγόμενου κειμένου σε μορφότυπο `.docx` ή `.html`, σε προκαθορισμένο φάκελο του συστήματος. Στην εν λόγω

υποενότητα εφαρμόζεται συνειδητά απόκλιση από την ενιαία διάταξη των στηλών της εφαρμογής, με την παροχή αυξημένου χώρου στη δεξιά στήλη. Εκεί προβάλλονται κείμενα από το προσωπικό αρχείο του συντάκτη, ώστε να είναι δυνατή η αξιοποίηση σημειώσεων, τεκμηρίων και αρχειακού υλικού κατά τη διαδικασία σύνταξης.

4.2 Newsroom Tools

Στην κεντρική περιοχή της υποενότητας **Newsroom Tools**, ο χρήστης μπορεί να εισαγάγει το κείμενό του και να το επεξεργαστεί περαιτέρω με τη βοήθεια σειράς αυτοματοποιημένων εργαλείων. Τα εργαλεία αυτά αξιοποιούν σύγχρονα γλωσσικά μοντέλα και υπηρεσίες τεχνητής νοημοσύνης και περιλαμβάνουν:

- πρόταση τίτλου είδησης, με χρήση του μοντέλου `AutoModelForSeq2SeqLM.from_pretrained("dascim/greekbart-news24-title")`,
- αυτόματη σύνοψη κειμένου, με χρήση του μοντέλου `AutoModelForSeq2SeqLM.from_pretrained("dascim/greekbart-news24-abstract")`,
- εξαγωγή βασικών σημείων μέσω κατάλληλου προτροπικού κειμένου (prompt) σε περιβάλλον *DeepSeek*,
- ορθογραφική και γλωσσική διόρθωση με αξιοποίηση του μοντέλου *Mistral*,
- μετασχηματισμό απομαγνητοφωνημένου λόγου σε δημοσιογραφικό ρεπορτάζ, με χρήση του *Mistral*,
- επαναδιατύπωση ειδησεογραφικού κειμένου μέσω αντίστοιχου προτροπικού πλαισίου,
- μετάφραση κειμένου από την αγγλική στην ελληνική γλώσσα, με χρήση του μοντέλου *Helsinki-NLP/opus-mt-en-el* μέσω της πλατφόρμας Hugging Face.

4.3 Transcribe

Η υποενότητα **Transcribe** παρέχει λειτουργίες απομαγνητοφώνησης προφορικού λόγου. Συγκεκριμένα, υποστηρίζεται η εισαγωγή συνδέσμου από την πλατφόρμα YouTube, με αξιοποίηση της βιβλιοθήκης *YouTubeTranscriptApi*, καθώς και η φόρτωση αρχείων ήχου σε μορφότυπο `.mp3`. Για την απομαγνητοφώνηση αρχείων ήχου χρησιμοποιείται το μοντέλο `whisper.load_model("medium")`, το οποίο επιτρέπει την αυτόματη μετατροπή προφορικού λόγου σε γραπτό κείμενο.

4.4 OCR

Στην υποενότητα **OCR** παρέχεται η δυνατότητα οπτικής αναγνώρισης χαρακτήρων (Optical Character Recognition), με αξιοποίηση της βιβλιοθήκης *pytesseract*. Η λειτουργία αυτή επιτρέπει την εξαγωγή κειμένου από αρχεία εικόνας ή σαρωμένα έγγραφα.

4.5 From one to another

Η υποενότητα **From one to another** προσφέρει εργαλεία μετατροπής αρχείων μεταξύ διαφορετικών μορφότυπων, υποστηρίζοντας τις ακόλουθες μετατροπές:
DOCX → TXT, TXT → DOCX, PDF → TXT, TXT → PDF, JSON → CSV, CSV → JSON, DOCX → PDF και PDF → DOCX.
Η λειτουργία αυτή ενισχύει τη διαλειτουργικότητα της εφαρμογής και διευκολύνει την αξιοποίηση υλικού από ετερογενείς πηγές.

5. Economy Tools

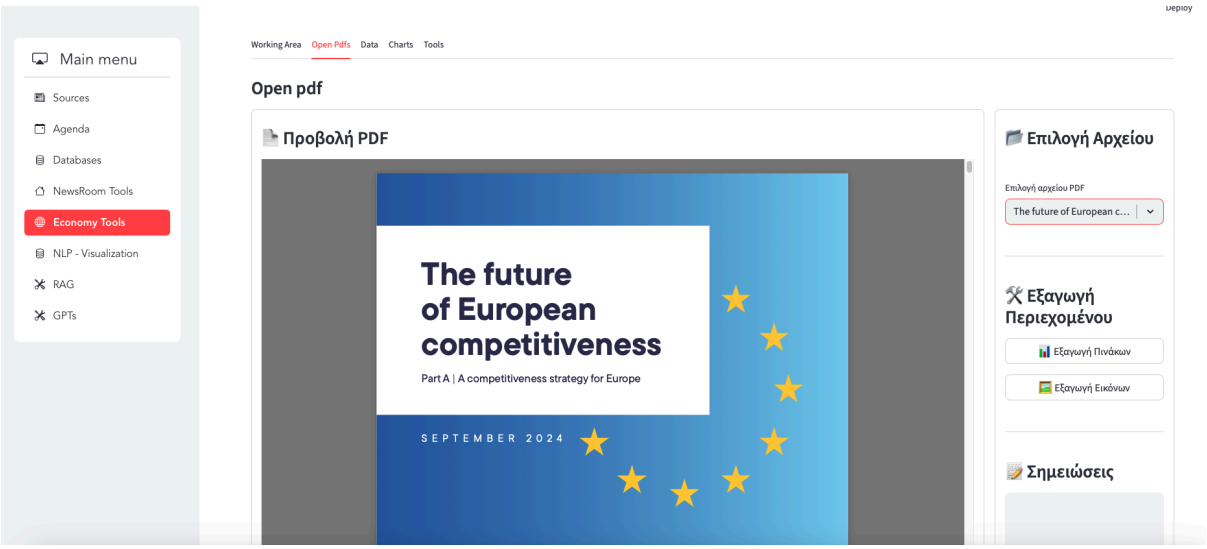

Εικόνα 5 - Αποψη της ενότητας "Economy Tools"

Στην παρούσα ενότητα συγκεντρώνονται εργαλεία που υποστηρίζουν την ανάγνωση, επεξεργασία και ανάλυση οικονομικών δεδομένων και σχετικής βιβλιογραφίας, λαμβάνοντας υπόψη τις ιδιαίτερες απαιτήσεις που χαρακτηρίζουν το συγκεκριμένο πεδίο. Ενδεικτικά, περιλαμβάνονται λειτουργίες για την επεξεργασία οικονομικών καταστάσεων και αρχείων τύπου CSV ή Excel, τη δημιουργία και παρουσίαση διαγραμμάτων, την ανάγνωση εκτενών εκθέσεων σε μορφή PDF από οργανισμούς και ερευνητικά ινστιτούτα, καθώς και υποστηρικτικά εργαλεία (όπως λεξικά οικονομικών όρων) που διευκολύνουν την κατανόηση εξειδικευμένων εννοιών.

Τα εργαλεία αυτά οργανώνονται στις ακόλουθες υποενότητες.

5.1 Working Area

Η υποενότητα *Working Area* λειτουργεί ως κεντρικός χώρος εργασίας. Ο χρήστης έχει τη δυνατότητα να επιλέξει και να ανοίξει διαφορετικού τύπου αρχεία, όπως CSV, διαγράμματα ή αρχεία PDF, μέσω του αντίστοιχου μενού επιλογών. Το επιλεγμένο περιεχόμενο προβάλλεται στον κεντρικό χώρο της εφαρμογής, όπου ο χρήστης μπορεί παράλληλα να καταγράφει σύντομες σημειώσεις. Με τον τρόπο αυτό υποστηρίζεται μια ενιαία ροή εργασίας, που συνδυάζει την ανάγνωση, την παρατήρηση και την πρωτογενή ανάλυση του υλικού.

5.2 Open PDFs

Δεδομένου ότι η μελέτη οικονομικών θεμάτων προϋποθέτει συχνά την ανάγνωση εκτενών εκθέσεων σε μορφή PDF και την εξαγωγή στοιχείων από αυτές, υλοποιήθηκε ένα αυτοτελές περιβάλλον με αυξημένες δυνατότητες επεξεργασίας αρχείων PDF. Στο συγκεκριμένο πεδίο ο χρήστης μπορεί, μέσω του control panel και του κεντρικού χώρου, να ανοίξει επιλεγμένα αρχεία PDF από προκαθορισμένο φάκελο, να εξάγει εικόνες και πίνακες, να καταγράφει σημειώσεις, καθώς και να εξάγει το κείμενο είτε συγκεκριμένων σελίδων είτε ολόκληρου του εγγράφου σε μορφή αρχείου TXT. Οι λειτουργίες αυτές διευκολύνουν την επαναχρησιμοποίηση και περαιτέρω ανάλυση του περιεχομένου.

5.3 Data

Η υποενότητα *Data* περιλαμβάνει εργαλεία που αφορούν τη συγκέντρωση, επεξεργασία και ανάγνωση οικονομικών δεδομένων. Ενδεικτικά, στον κεντρικό χώρο εμφανίζεται εξ ορισμού ένας πίνακας με τις μεγαλύτερες εταιρείες, ενώ παρέχεται η δυνατότητα πρόσβασης σε εξωτερικές πηγές δεδομένων, όπως το μητρώο του ΓΕΜΗ και η ιστοσελίδα *financials.gr*, οι οποίες συγκεντρώνουν οικονομικά στοιχεία επιχειρήσεων. Επιπλέον, μέσω του μενού επιλογών υποστηρίζεται η εισαγωγή και προβολή ημιδομημένων δεδομένων (π.χ. σε μορφή YAML), η μετατροπή τους σε αρχεία JSON, καθώς και η αναζήτηση εντός αυτών. Τέλος, δίνεται η δυνατότητα ανεβάσματος και επεξεργασίας αρχείων CSV ή Excel, ενισχύοντας την ευελιξία του εργαλείου στη διαχείριση διαφορετικών τύπων δεδομένων.

5.4 Charts

Στην υποενότητα *Charts* ο χρήστης έχει τη δυνατότητα να δημιουργεί διαγράμματα με τη χρήση της βιβλιοθήκης Plotly, βασισμένα σε επιλεγμένα αρχεία Excel. Παρέχονται βασικές επιλογές οπτικοποίησης, όπως ραβδογράμματα, γραμμικά διαγράμματα, διαγράμματα πίτας και διαγράμματα διασποράς (scatter plots). Τα παραγόμενα διαγράμματα μπορούν να αποθηκευτούν και να επαναχρησιμοποιηθούν. Η λειτουργικότητα αυτή συμβάλλει στην

οπτικοποίηση οικονομικών δεδομένων και διευκολύνει την ερμηνεία και κατανόησή τους. Επιπλέον, ο χρήστης μπορεί να προβάλλει διαγράμματα που έχουν αποθηκευτεί σε συγκεκριμένο φάκελο, καθώς και να πραγματοποιεί αναζήτηση με λέξεις-κλειδιά.

5.5 Tools

Η υποενότητα *Tools* παρέχει εργαλεία υποστήριξης της ανάλυσης οικονομικών κειμένων. Ο χρήστης μπορεί να εισάγει ένα κείμενο στον κεντρικό χώρο και, μέσω των αντίστοιχων επιλογών, να ζητήσει από το γλωσσικό μοντέλο Mistral τη δημιουργία μιας «οικονομικής σύνοψης», η οποία παρουσιάζει τα βασικά οικονομικά δεδομένα του κειμένου σε μορφή συνοπτικών σημείων (bullet points) και πινάκων, κατάλληλων για περαιτέρω αξιοποίηση. Εναλλακτικά, παρέχεται η δυνατότητα αυτόματης επισήμανσης οικονομικών όρων του κειμένου και εμφάνισης υπερσυνδέσμων προς εξωτερικό λεξικό οικονομικών όρων, διευκολύνοντας την ερμηνεία εξειδικευμένης ορολογίας.

6. NLP - Visualization

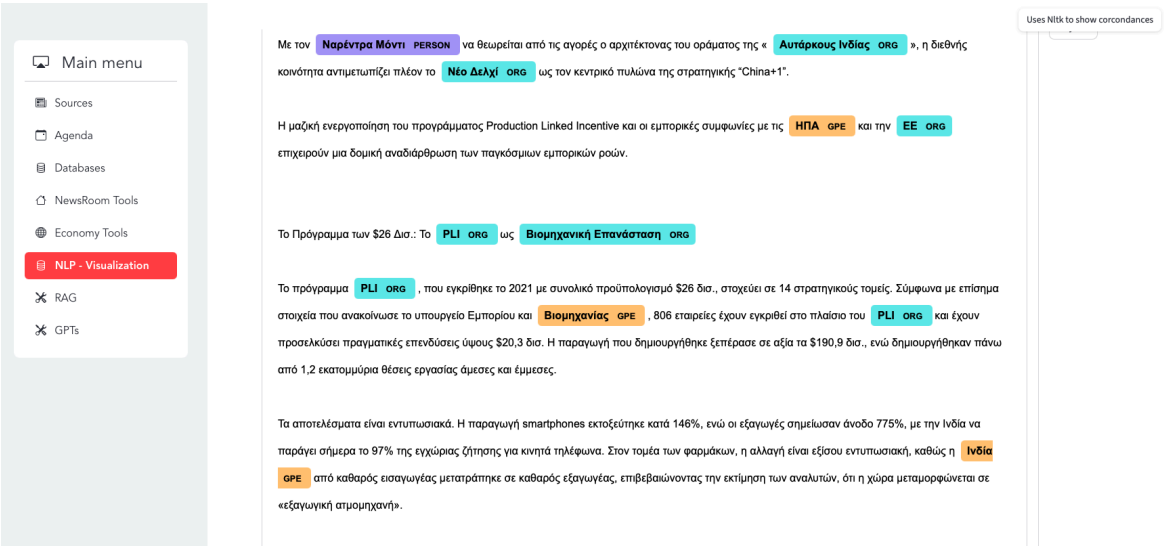

Εικόνα 6 - Στιγμιότυπο από την ενότητα NLP - Visualization

Η υποενότητα NLP συγκεντρώνει εργαλεία επεξεργασίας φυσικής γλώσσας που υποστηρίζουν την ανάλυση και οπτικοποίησης κειμένων, οικονομικών στοιχείων και εκθέσεων. Το περιβάλλον παρέχει μια διαδραστική διεπαφή όπου ο χρήστης μπορεί να εισάγει κείμενο, να εφαρμόσει διαφορετικές τεχνικές ανάλυσης και να εξάγει αποτελέσματα σε εύληπτη μορφή.

6.1 NLP

Στην υποενότητα αυτή οι βασικές λειτουργίες περιλαμβάνουν:

- **Επισήμανση Οντοτήτων (Highlighting):** Χρήση της βιβλιοθήκης SpaCy για τον εντοπισμό και την επισήμανση σημαντικών οντοτήτων όπως πρόσωπα, οργανισμοί και τοποθεσίες. Ο χρήστης μπορεί να βλέπει άμεσα τις οντότητες μέσα στο κείμενο, διευκολύνοντας την αναγνώριση κρίσιμων πληροφοριών.
- **Εξαγωγή Προσώπων και Οργανισμών (Persons and Organizations):** Δυνατότητα εξαγωγής οντοτήτων συγκεκριμένων κατηγοριών μέσω του NLP, επιτρέποντας τη δημιουργία συνόλων δεδομένων με αναφορά σε πρόσωπα και οργανισμούς που εμφανίζονται στο κείμενο.
- **Εντοπισμός Ημερομηνιών (Find Dates):** Χρήση κανονικών εκφράσεων (regex) για την αναγνώριση και εξαγωγή ημερομηνιών, σημαντική για τη χρονική οργάνωση οικονομικών γεγονότων.
- **Συμφωνία και Ομοιότητα Κειμένων (Similarity & Concordances):** Δυνατότητα υπολογισμού ομοιότητας μεταξύ δύο κειμένων και δημιουργίας πίνακα συμφωνίας (concordance) γύρω από συγκεκριμένες λέξεις-κλειδιά, υποστηρίζοντας τη λεπτομερή ανάλυση και τη συσχέτιση εννοιών.
- **Ενσωμάτωση εξωτερικών εργαλείων (Voyant Tools):** Δυνατότητα ενσωμάτωσης διαδικτυακών εργαλείων οπτικοποίησης κειμένου για πιο εκτενή αναλύση και στατιστικά γραφήματα λέξεων.

6.2 Relation Extraction

Η υποενότητα Relation Extraction υποστηρίζει τη δημιουργία διαγραμμάτων που απεικονίζουν σχέσεις μεταξύ οντοτήτων, όπως εταιρείες, πρόσωπα και όροι. Το περιβάλλον παρέχει:

- **Διάγραμμα Σχέσεων από Excel (Relation extraction):** Δημιουργία διαδραστικών γραφημάτων βασισμένων σε δεδομένα από αρχεία Excel, χρησιμοποιώντας τη βιβλιοθήκη PyVis.
- **Διάγραμμα πολλαπλών σχέσεων (More than 2):** Υποστήριξη για διαγράμματα που περιλαμβάνουν περισσότερες από δύο οντότητες, επιτρέποντας σύνθετη αναπαράσταση δικτύων.
- **Διάγραμμα από JSON:** Δυνατότητα δημιουργίας γραφήματος από δομές JSON, διευκολύνοντας την ενσωμάτωση εξωτερικών ή προ-επεξεργασμένων δεδομένων.

Με τον τρόπο αυτό, το NLP περιβάλλον και η ανάλυση σχέσεων προσφέρουν στον χρήστη ένα ολοκληρωμένο εργαλείο για την κατανόηση και την οπτικοποίηση σύνθετων οικονομικών πληροφοριών.

7. GPTs - RAGs